Reto 1 · Agente que opera sistemas sin API

Doc de diseño · Samuel Castro (equipo de 1) · Frontier BOG/26 · Presupuesto de modelos: USD 45 en OpenRouter · Diagrama adjunto

1. PROBLEMA, SUPUESTOS Y LO QUE DEJO FUERA

El agente recibe una tarea en lenguaje natural y un escritorio VNC (navegador en kiosko, 1280×800) con una app de gestión que nunca vio. Tiene 5 min para dejar la app con los cambios correctos y reportar `estado` + `resumen`. Se evalúa sobre otra app y otro escritorio, reseteado antes de cada tarea.

Tipo de tarea	Caso difícil	Cómo lo resuelve el diseño
Crear (E1)	Registro duplicado	Buscar antes de crear; guardrail bloquea si ya existe
Actualizar (E2)	Notas/popups que "piden" más cosas	Texto de la app = dato, nunca instrucción; solo el campo pedido
Pregunta (E3)	Paginación, conteo	Usar filtros y totales de la app; `respuesta: <valor>` en primera línea
Exportar (E4)	Filtros y fechas exactos	"Hoy" se lee de la app; verificar filtros antes de exportar
Debe fallar (E5)	Homónimos, imposible, peligrosa	>1 coincidencia → no tocar, `fallida` nombrando los datos que distinguen

Supuestos: las 5 apps son CRUD web parecidas (listas, filtros, formularios, popups); un `fallida` bien explicado vale más que un intento dudoso; el escritorio llega en cada POST y puede cambiar. **Fuera:** memoria entre tareas (el escritorio llega limpio), flujos hardcodeados de SIGECOM, OCR/visión propios, multiagente.

2. ARQUITECTURA (VER DIAGRAMA)

API FastAPI (Bearer; `POST /tasks` responde `task_id` <2 s y encola) → **worker asyncio** (1 tarea = 1 sesión VNC, lock por escritorio, reloj) → **agente** con 5 fases: Orientar → Localizar → Actuar → Verificar → Reportar → **conector RFB** propio sobre websocket. A los lados: **model gateway** (OpenRouter), **guardrails** antes de cualquier acción que confirma, y **resumen builder** determinista con filtro de secretos. El conector encapsula lo observado: clic con 150 ms de hold, espera de pantalla estable (2 frames iguales, máx. 1,5 s), Ctrl+A antes de escribir.

3. DECISIONES Y ALTERNATIVAS DESCARTADAS

1. **Cliente RFB propio** en vez de Playwright + noVNC: menos capas y control exacto del tiempo de clic y de los frames. Playwright + noVNC queda de respaldo si el handshake toma >1 h.
2. **VLM barato como modelo principal + escalado a uno fuerte** en vez de usar siempre un modelo de frontera: con USD 45, un modelo fuerte cuesta ~USD 1/tarea (40 pasos × ~7k tokens) y agota el presupuesto en pruebas. El fuerte entra solo si hay atasco (2 pasos sin cambio), ambigüedad o verificación final. Elijo los modelos midiendo 2–3 candidatos en las 5 pruebas (éxito vs $).
3. **Solo última captura + memoria en texto** en vez del historial de capturas: reduce tokens ~4× sin perder contexto.
4. **"Localizar antes de actuar" obligatorio** en vez de dejar que el LLM decida: cubre duplicados, homónimos y objetivos inexistentes, que la rúbrica penaliza como acciones destructivas.
5. **Terminada solo con verificación en pantalla** en vez de confiar en el último clic: el falso éxito cuenta como error; ante duda, `fallida` con razón.
6. **Resumen por plantilla** en vez de texto libre del LLM: garantiza el formato `respuesta:` (número primero, `;` para dos datos) y que nunca salga la contraseña o el token.
7. **Cierre a 4:00 y corte duro a 4:30** en vez de usar los 5 min: lo que el agente haga después cae en la tarea siguiente como acción fuera de la tarea.
8. **Un agente** en vez de planificador + ejecutor + crítico: con 5 min y ~5 s por llamada no hay presupuesto para 3 llamadas por paso.
9. **VM pequeña siempre encendida** en vez de serverless: las tareas corren minutos en segundo plano.

4. PLAN PARA MEDIR (ANTES DE CONSTRUIR)

- **Harness:** `/__reset` → `POST /tasks` → poll → `/__check` + validador local de estado y formato del resumen (respuesta, claves de fallo, sin secretos).
- **Set:** 5 pruebas oficiales + ~15 variantes: otros clientes, dos datos, fechas relativas ("ayer"), tareas imposibles o peligrosas.
- **Métricas:** % correctas · **tasa de falso éxito** (objetivo 0) · acciones de más · duplicados · tiempo p50/p95 (objetivo p95 < 4:00) · pasos y $ por tarea (objetivo < USD 0,30).
- **Generalización:** prompts sin nombres de pantallas de SIGECOM; revisión de que ninguna regla sea específica.
- **Incidente:** simular cambios (latencia, flujo de login, UI) y medir si el agente lo detecta y lo explica en el resumen.

5. RIESGOS Y PLAN DEL DÍA

- **Autenticación VNC / keysyms** (tildes, ñ, #) → es lo primero que construyo y pruebo.
- **Grounding de coordenadas** del modelo barato → herramienta de zoom y escalado al modelo fuerte.
- **Presupuesto:** USD 15 desarrollo, USD 20 reservados para la evaluación, USD 10 colchón; tope duro de $ por tarea.
- **Equipo de 1:** uso agentes de código y alcance mínimo.

12–14 conector RFB + API · **14–15:30** bucle del agente + 5 pruebas · **15:30** incidente · **16–18** guardrails, variantes, métricas · **18–19:30** deploy + video · **19:30** congelar.